CIMMI

2440, chemin Sainte-Foy
Québec (Québec, Canada)
418-781-2464

Compte-rendu

Nutriss

Extraction de données sur fax pour optimiser le temps de travail

Ce document présente un détail des travaux réalisés par le CIMMI dans le cadre du projet AUTRE-NUTRISS-OCRApp. Il est mis à jour sur une base généralement hebdomadaire, selon la disponibilité de l'équipe de développement et des nouveaux avancements à communiquer.

Équipe du CIMMI

L'équipe de développement du CIMMI est composée de ces personnes:

- Alexandre Laberge, développeur logiciel
- Denis Boulanger, directeur de la recherche et du développement

Équipe

L'équipe est composée de ces personnes:

Historique des travaux

[date] 2025

Réunion de démarrages

23 juin 2025

Présentation de la démo

Une démonstration a été proposé à NUTRISS pour montrer l’efficacité de la détection OCR pour extraire certaines données des fax.
Le but ultime est d’accélérer le processus de rentrer et valider les données qui sont rentré dans leur système.

La démo

La démonstration comprend 2 modes d’utilisations :

Analyse manuelle

Ce mode est utilisé pour représenter l'ancienne façon de faire pour entrer les données dans le système.

Les étapes de ce mode sont :

1. L'utilisateur entre les données dans le tableau manuellement pour chaque champ.

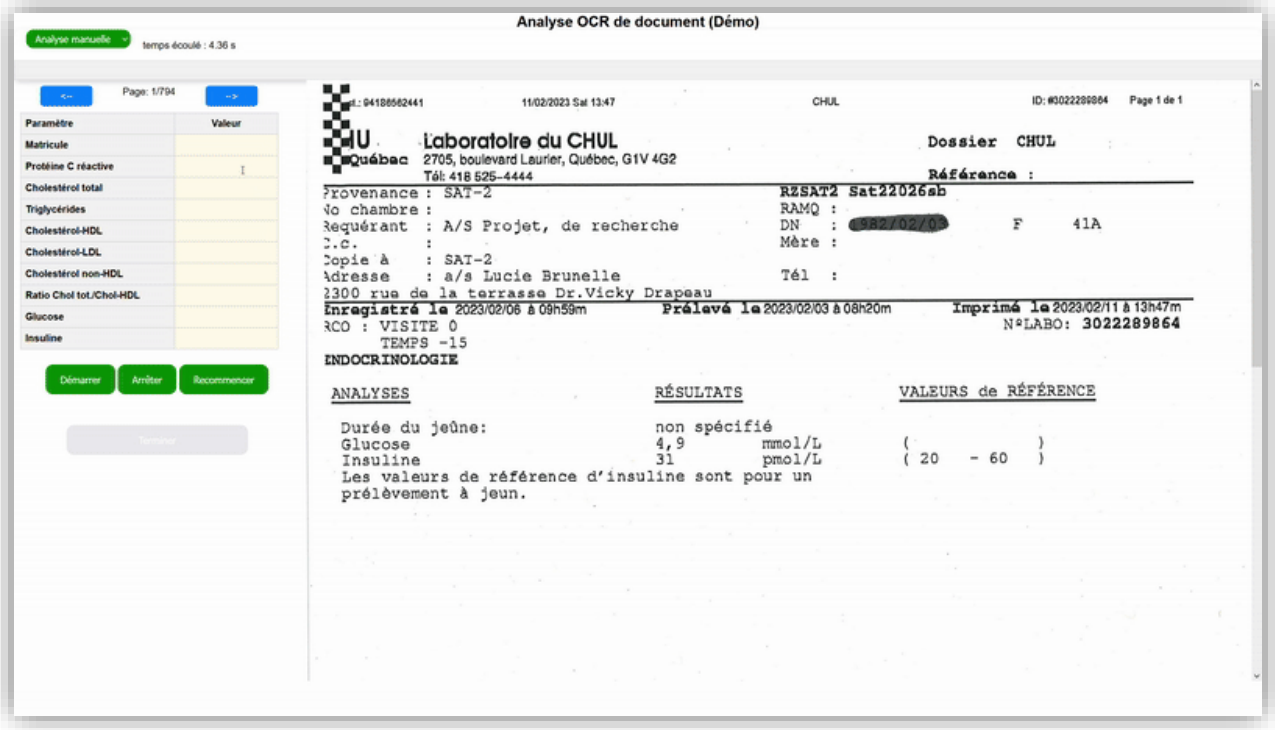

2. Une fois la page terminée, l'utilisateur clique sur la flèche pour accéder à la prochaine page
3. Quand toutes les pages sont terminées, les informations sont enregistrées et stockées dans une base de données (Google Cloud Storage)

Validation OCR

Ce mode est la nouvelle technique utilisant la détection par intelligence artificielle (**analyse OCR**).

Les étapes de ce mode sont :

1. L'utilisateur utilise la liste déroulante et choisi l'option **Validation OCR**

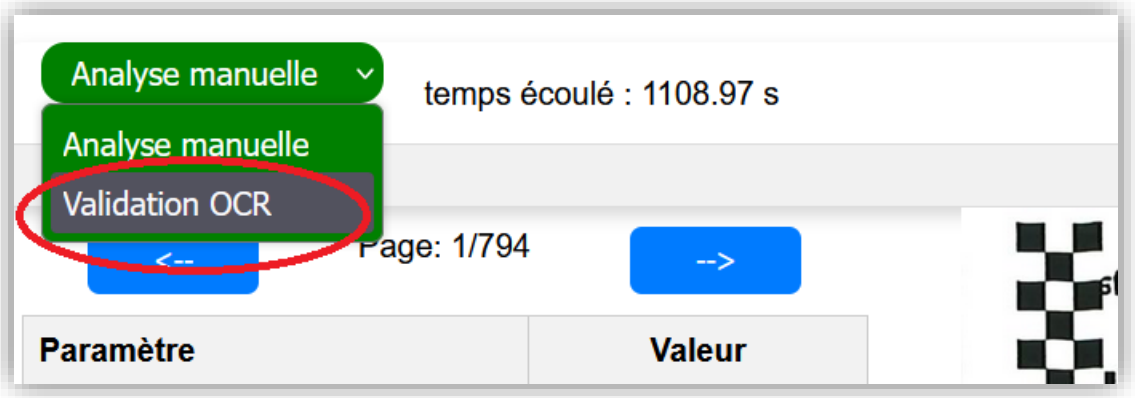

2. Une fois l'analyse OCR terminée, les champs remplis sont validés par l'intelligence artificielle
3. On complète les champs manquants ou incorrects
4. On répète les étapes 2 et 3 pour chacune des pages
5. Quand toutes les pages sont terminées, les informations sont enregistrées et stockées dans une base de données (Google Cloud Storage)

Test et Résultat du dev

Voici les résultats obtenus lors des tests effectués.

Test pour comparer l'efficacité de la détection OCR:

Pour les documents suivants:

- 0d7f2764 (**SAT-2026 à 2041**)
- 17d4e5dc (**SAT-1004 à 1007**)
- 1b95f0df (**SAT-2066 à 2103**)
- 22433577 (**SAT-2051 (feuille unique)**)
- 3dc81e85 (**SAT-1018 à 2013+2058**)

* Certains document ont été tourné pour s'assurer que les pages soient du bon sens.
* Ceci équivaut à 377 pages de document pdf

Différents tests avec divers nombres de threads (4 threads permet 4 requêtes en même temps, 5 threads pour 5 requêtes, etc…) pour voir si l'IA reçoit trop de requête en même temps et peut causer des erreurs.

Nb de thread	*4 threads*	*12 threads*
Moyenne (%)[1]	50.5	50.6
Minimum (%)[2]	0	0
Maximum (%)[3]	100	100
Écart-type[4]	41.22	40.63

On remarque bien que le pourcentage ne monte pas peu importe le nombre de thread, cela signifie donc qu'il reste seulement à ajuster le modèle pour obtenir de meilleur résultat.

Test pour observer l'efficacité des 2 méthodes

Ce test consistait à utiliser les deux méthodes et comparer le temps nécessaire pour compléter la saisie des données.

Analyse manuelle :

- Pour 100 pages:
  - Temps total: 1773.64 secs = 29 min 33 secs
- Pour 200 pages:
  - Temps total: 3270.49 secs = 54 min 30 secs

Validation OCR :

- Analyse OCR (pour les 794 pages): 423.464 secs = environ 7 minutes
- Analyse OCR (pour 377 pages[5]): 204.41 secs = 3 min 24 secs
- Pour 100 pages:
  - Validation OCR: 837.49 secs = environ 14 minutes
  - Temps total (analyse 794 + validation) : 1260.954 secs = environ 21 minutes

[1] La **moyenne** représente le pourcentage moyen de champs correctement détectés par page, en comparant chaque champ extrait avec la base de données de référence.
[2] Le **minimum** correspond au plus faible taux de correspondance observé sur une page, c'est-à-dire la page ayant le moins de champs détectés correctement.
[3] Le **maximum** indique le taux le plus élevé de correspondance, soit une page où tous les champs ont été détectés correctement.
[4] L'**écart-type** mesure la dispersion des pourcentages de correspondance entre les pages. Une valeur élevée indique une forte variabilité dans la qualité de détection d'une page à l'autre.
[5] Utilise les mêmes documents que le test d'avant.

    - Temps total (analyse 377 + validation) : 1041.9 secs = environ 17 minutes 24 sec

- Pour 200 pages:
    - Validation OCR: 1526.69 secs = 25 min 26 secs
    - Temps total (377): 1731.1 secs = 28 min 50 secs
    - Temps total (794): 1950.154 secs = 32 min 30 secs

- Pour 300 pages:
    - Validation OCR: 2252.27 secs = environ 37 min 30 sec

- Pour 377 pages:
    - Validation OCR: 2786.86 secs = environ 46 min 26 sec

Conclusion :

Voici les observations faites et les améliorations possibles pour le projet.

- L'analyse par intelligence artificielle ajoute du temps au départ de la validation OCR, mais est avantageux à grande échelle
- Temps moyen nécessaire pour traiter **100 pages**:
    - Validation OCR : environ 12 minutes
    - Analyse manuelle: environ 27 minutes
- Temps prévu pour traiter **800 pages** :
    - Validation OCR :
        - 12 * 8 + 7 minutes d'analyse = 103 minutes = 1 heures 43 minutes
    - Analyse OCR :
        - 27 * 8 = 216 minutes = 3 heures 36 minutes
    - On sauve 1 heure et 53 minutes avec la méthode de validation OCR
- Modèle non complété donc place à l'amélioration de précision pour OCR
- Le modèle d'intelligence artificielle n'est pas finalisé et aurait besoin d'être peaufiné
- Débloquer les quotas d'api pourrait aider à accélérer le processus d'analyse OCR pour réduire le temps d'exécution total du mode de validation OCR

14 juillet 2025

Envoi de la démo

La version finale de la démo a été complétée et transmise au client. Elle intègre plusieurs améliorations.

Interface utilisateur :

- La table des champs à remplir est désormais présentée dans un ordre constant afin de faciliter la saisie.
- Il est maintenant possible d'accéder à n'importe quelle page directement depuis la première.

Stockage d'information :

- Lors du choix du type de traitement, les utilisateurs doivent saisir un nom d'utilisateur afin de pouvoir travailler, enregistrer leur progression et reprendre leur travail ultérieurement.

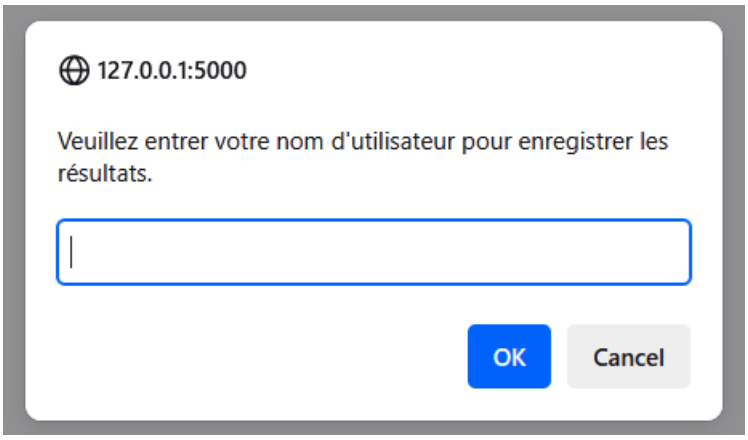

- Lors de l'enregistrement des données, si un répertoire existe déjà pour cet utilisateur, les nouvelles données y sont enregistrées.
- Exemple de structure :
    - Validation
        - Alex
            - Données
        - Antoine
            - Données
        - Olivier
            - Données

Il ne reste maintenant qu'à effectuer les tests utilisateurs. Une fois ceux-ci terminés, il faudra procéder à l'extraction des résultats.

Semaine du 11 août 2025

Entrainement d'un modèle d'IA

Durant cette semaine, le focus était sur l'entrainement du nouveau modèle pour détecter automatiquement certains champs cochés sur des fax numérisés.

Les champs à détecter sont des boites à cocher pour les options **Oui**, **Partiellement** et **non**. Il y en aura d'autre par le futur, mais ce sont les premiers à faire.

Voici un exemple de document à analyser :

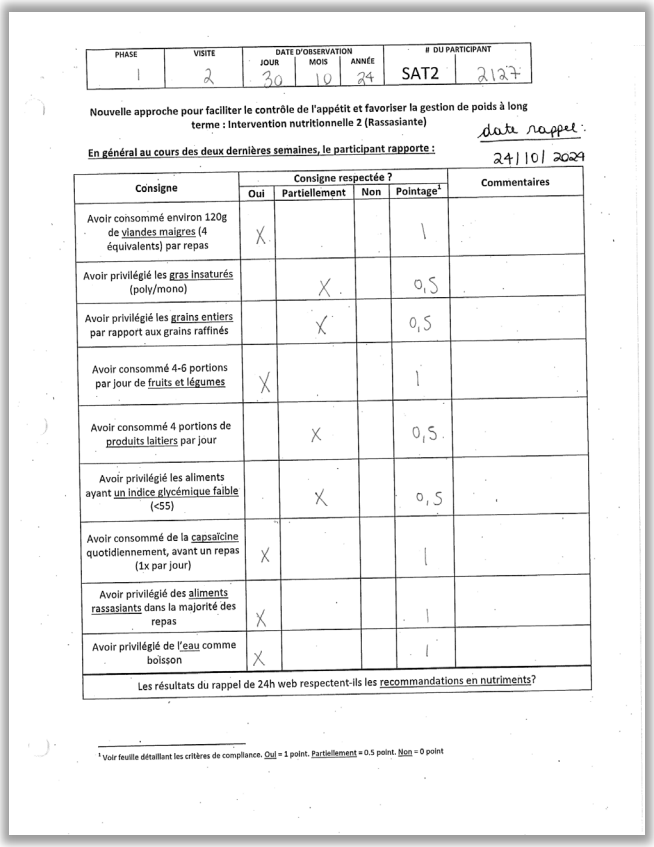

PHASE	VISITE	DATE D'OBSERVATION JOUR	MOIS	ANNÉE	# DU PARTICIPANT	
1	2	30	10	24	SAT2	2127

Nouvelle approche pour faciliter le contrôle de l'appétit et favoriser la gestion de poids à long terme : Intervention nutritionnelle 2 (Rassasiante)

date rappel : 24/10/2024

En général au cours des deux dernières semaines, le participant rapporte :

Consigne	Consigne respectée ? Oui	Partiellement	Non	Pointage[1]	Commentaires
Avoir consommé environ 120g de viandes maigres (4 équivalents) par repas	X			1	
Avoir privilégié les gras insaturés (poly/mono)		X		0,5	
Avoir privilégié les grains entiers par rapport aux grains raffinés		X		0,5	
Avoir consommé 4-6 portions par jour de fruits et légumes	X			1	
Avoir consommé 4 portions de produits laitiers par jour		X		0,5	
Avoir privilégié les aliments ayant un indice glycémique faible (<55)		X		0,5	
Avoir consommé de la capsaïcine quotidiennement, avant un repas (1x par jour)	X			1	
Avoir privilégié des aliments rassasiants dans la majorité des repas	X			1	
Avoir privilégié de l'eau comme boisson	X			1	
Les résultats du rappel de 24h web respectent-ils les recommandations en nutriments?					

[1] Voir feuille détaillant les critères de compliance. Oui = 1 point. Partiellement = 0.5 point. Non = 0 point

Difficultés

- Les images sont parfois inclinées de quelques degrés, ce qui complique la création de *bounding boxes* aux contours précis.
- Les cases à cocher ne sont pas toujours cochées de la même façon (ex. : **X** tapuscrit, **X** manuscrit ou ✓ manuscrit).

14 août 2025

Rencontre pour les résultats du test client

Lors de cette rencontre, les résultats des tests réalisés par les deux testeurs ont été présentés au client. La suite du projet a également été évoquée brièvement.

Résultat

Observation clé : L'OCR est environ **2× plus rapide** que l'analyse manuelle, avec une précision comparable.

Mode d'analyse	Testeur	Moyenne (%)	Min (%)	Max (%)	Écart-type	Total erreurs	Remarques
Manuelle	1	99,9	80,0	100,0	1,27	11	90 % → 9× ; 80 % → 1×
	2	99,9	70,0	100,0	1,46	11	90 % → 8× ; 70 % → 1×
OCR	1	99,8	80,0	100,0	1,41	14	90 % → 12× 80 % → 1×
	2	98,7*	70,0*	100,0*	4,30*	15*	Données du doc *569c1f5a* manquantes*

*
Valeurs invalides en raison de données manquantes.

Types d'erreurs à surveiller

- **Matricule** : vérifier la présence et la validité du numéro.
- **Insuline** : champ souvent le moins bien détecté par l'IA.
- **Glucose** : vérifier la présence du point décimal pour éviter les valeurs faussement élevées (ex. : 54 au lieu de 5.4).

Problèmes rencontrés

- Perte des données pour le document *569c1f5a* pour un des testeurs, entraînant une réduction artificielle du temps total d'analyse.

Suite du projet

- **Ajout de pages à analyser** pour l'intelligence artificielle.

- **Améliorations du site** :
    - Ajout du zoom avant/arrière
    - Rotation d'image
    - Réentraînement d'une image spécifique

- **Base de données** :
    - **Restauration d'anciennes fonctions** retirées de la démo.
    - Script actuel pour l'export en CSV → prévoir un changement de format vers .xlsx.
        - Voici la structure que le .xlsx devrait avoir :

Une cellule contenant un point écrasera la donnée dans la base de données

Informations de projet						Liste de variables (à remplir)																	
Section	Centre	Participants	Sequence	Traitement	Visites	glu-15	ins-15	glu0	ins0	glu30	ins30	glu60	ins60	glp1	pyy	ghrelin	leptine	il6	crp_elisa	chol	tg	hdlc	ldlc
Projet	INAF	001			T0																		
Projet	INAF	002			T0																		
Projet	INAF	003			T0																		
Projet	INAF	001			T6																		
Projet	INAF	001			T18																		