CIMMI
2440, chemin Sainte-Foy
Québec (Québec) G1V 1T2
(418) 781-2464

Rapport technique

Développement d'une application pour l'extraction automatique de données à partir de documents structurés par IA

SOUMIS À	PAR
Vicky Drapeau, Ph. D., Dt.P Professeure titulaire 2300, rue de la Terrasse, local 0290 G PEPS, Université Laval Québec (Québec) G1V 0A6 Tél.: 418-656-2131 poste 402757 Courriel: vicky.drapeau@kin.ulaval.ca	CIMMI Denis Boulanger Ph.D. Alexandre Laberge 2440 chemin Sainte-Foy Québec, QC G1V 1T2 Courriel : dbouanger@cimmi.ca

22 sept. 2025

cimmi.ca

1.1 Description

L'application NutriProof permet de gérer, d'analyser et de valider des documents PDF (par exemple, des bilans nutritionnels) grâce à la reconnaissance de texte (OCR) et à l'intelligence artificielle. Elle propose une interface web pour déposer, visualiser, annoter et exporter les résultats. L'application automatise ainsi la gestion documentaire et l'extraction de données, tout en sécurisant les fichiers sur le cloud.

Un **guide de l'usager**, présentant les principales caractéristiques de l'application, est disponible en ligne à l'adresse suivante : https://nutriss.cimmi-dev.ca/

1.2 Tests de validation

L'objectif initial du projet était de réduire le temps consacré à la saisie des formulaires. Actuellement, ce travail est effectué manuellement :

- Des étudiants lisent chaque formulaire et saisissent les données pertinentes dans un fichier Excel.
- Une deuxième personne refait la saisie des mêmes formulaires.
- Les deux fichiers sont ensuite comparés, et en cas de différence, une troisième personne intervient pour trancher.

Ce processus est long, répétitif et sujet aux erreurs. Le système applicatif que nous proposons vise à automatiser la lecture et la validation, afin de réduire considérablement le temps requis pour la validation tout en améliorant la fiabilité des données.

Pour atteindre cet objectif, le système réalise d'abord une saisie automatique à l'aide des algorithmes d'intelligence artificielle de Google (*Document AI* et *Gemini*). Une fois les documents traités, une première personne doit valider les résultats et corriger les données. Cette étape est essentielle, car l'analyse automatique peut parfois rencontrer des difficultés dans la lecture de certaines informations. Les causes principales d'erreurs d'analyse sont : une page mal numérisée (croche, plié ou à l'envers) et des marques sur les valeurs (ex. : trait de crayon), ou une donnée mal identifiée (ex. : matricule du participant).

Une seconde personne peut également intervenir afin de confirmer ou ajuster la validation effectuée par la première. Pour faciliter ce processus, nous avons développé une application web dédiée, qui rend la saisie et la validation des données plus simples et efficaces.

L'hypothèse à la base du développement de cette application est que le temps requis pour valider des données générées automatiquement est beaucoup plus court que celui nécessaire à une saisie manuelle complète.

Afin d'évaluer cette hypothèse, nous avons mené des tests avec deux étudiantes de l'INAF.

- Dans un premier temps, chacune a effectué une saisie manuelle à l'aide de l'interface développée. Les tableaux présentés étaient vides et elles devaient entrer toutes les données à partir des formulaires.

- Dans un second temps, elles ont réalisé le même exercice, mais cette fois les tableaux étaient préremplis automatiquement grâce aux méthodes d'analyse intelligente. Leur tâche consistait alors uniquement à corriger et valider les données.

Au total, 794 pages réparties dans 12 fichiers différents ont été analysées. Certaines pages avaient été numérisées à l'envers et ont dû être réorientées. D'autres présentaient des plis lors de la numérisation, ce qui cachait parfois des informations importantes. Dans ces cas, une validation avec les versions papier a été nécessaire. Des recommandations ont été intégrées au guide de l'usager afin de réduire ce type d'erreurs lors de la numérisation.

Les performances ont été évaluées selon deux critères :

1. Le temps nécessaire pour compléter la saisie manuelle comparé au temps requis pour la correction et la validation.
2. Le taux d'erreurs de saisie, en comparant les résultats obtenus à un ensemble de données validées manuellement, utilisé comme vérité terrain.

Temps moyen nécessaire pour traiter **100 pages**:

Participant(e)	Méthode manuelle	Méthode assistée	Variations	Erreurs de saisi
#1	315 min.	163 min.	-47%	11-14 erreurs (1%)
#2	158 min.	103 min.	-34%	11-15 erreurs (1%)

Les résultats montrent une réduction du temps de saisie d'environ 34 à 47 pour cent lorsque l'on utilise la méthode proposée, comparativement à la saisie entièrement manuelle. Le taux d'erreurs est demeuré similaire entre les deux approches, ce qui confirme que l'automatisation n'a pas d'impact négatif sur la qualité des données.

Notez que le temps pris par la participante 2 est moindre, car un bogue est survenu durant les tests et qu'elle a complété seulement une partie des documents.

Il est important de noter que ce gain de temps ne prend pas en compte la durée d'exécution des algorithmes d'analyse des documents. En effet, ces traitements peuvent être effectués en lots en amont, de sorte qu'ils n'influencent pas directement le temps nécessaire aux utilisateurs pour la validation.

Nous estimons par ailleurs que la simple saisie manuelle au moyen du formulaire en ligne représente déjà un gain significatif comparativement à une méthode reposant sur un fichier Excel.

1.3 Migration de l'application

L'application fait appel à plusieurs services de Google Cloud Platform (GCP):

- **Google Cloud Storage (GCS)** : pour stocker les fichiers PDF, images et résultats d'analyse.
- **Google Document AI** : pour extraire automatiquement le texte et la structure des documents PDF (OCR avancé).
- **Google Compute Engine / App Engine (optionnel)** : pour héberger l'application web.

L'application dépend fortement de services cloud propriétaires, ce qui rend une migration vers un serveur local complexe, coûteuse et nécessitant de lourdes adaptations techniques.

- Il n'existe pas de version locale à Google Document AI : l'OCR avancée et l'extraction de structure ne peuvent pas être reproduites sans ce service.
- Le stockage cloud (GCS) gère la sécurité, la redondance et l'accès multi-utilisateur : un serveur local devrait réimplémenter ces fonctions.
- Les scripts et l'architecture sont conçus pour dialoguer avec les API Google, pas avec des outils locaux.

1.4 Frais d'utilisation

Les coûts principaux dépendent du volume de stockage, du nombre de pages traitées par l'OCR, et de l'hébergement serveur. Plus l'application traite de documents et de pages, plus les frais augmentent. Google fournit des estimateurs de coût pour chaque service sur son site officiel.

Selon nos estimations et les frais encourus durant les derniers mois d'utilisation, les frais peuvent varier de **30$ à 100$ par mois environ**.

Voici les principaux frais liés à l'utilisation de l'application NutriProof :

- **Ressources serveur (CloudRun) :** L'application est hébergée sur le cloud, il y a des frais pour le serveur (CPU, RAM, trafic réseau).
- **Stockage Google Cloud Storage (GCS) :** Facturation selon l'espace utilisé (Go/mois) pour les fichiers PDF, images et résultats.
- **Google Document AI (OCR avancé) :** Facturation à la page analysée (chaque page PDF envoyée à l'OCR est comptée).
- **Gemini (Google Generative AI) :** Facturation à l'utilisation : chaque appel à l'API Gemini (génération de texte, extraction intelligente, etc.) est facturé selon le nombre de tokens (mots/lettres) traités.

1.5 Conclusion et recommandations

NutriProof est une solution moderne et performante pour la gestion, l'analyse et la validation de documents nutritionnels grâce à l'intelligence artificielle. Elle permet de réaliser des gains significatifs en temps lors de la saisie et de la validation des données, tout en améliorant l'efficacité du processus.

À l'heure actuelle, l'application permet uniquement la lecture automatique des formulaires de tests sanguins. Des travaux supplémentaires seront nécessaires pour élargir ses capacités à d'autres types de formulaires. L'architecture développée est toutefois évolutive, ce qui facilitera l'intégration de ces nouvelles fonctionnalités au fur et à mesure de leur développement.

Recommandations :

- Privilégier l'utilisation sur le cloud pour bénéficier de la puissance, de la sécurité et de la scalabilité des services Google.
- Surveiller régulièrement les coûts liés à l'OCR, au stockage, à Gemini et à l'hébergement, surtout en cas de volumes importants.
- Former les utilisateurs à l'interface et aux bonnes pratiques pour optimiser l'utilisation et limiter les erreurs (voir guide de l'usager).
- Prévoir une assistance technique pour accompagner les utilisateurs et résoudre rapidement les éventuels problèmes.

Note importante

L'application est actuellement hébergée sur un compte Google Cloud Platform (GCP) payé par le CIMMI. Nous prendrons en charge les frais pour une période de quelques semaines seulement. Par la suite, il sera nécessaire de prévoir un transfert de la facturation vers le compte approprié.